

# KOHEN\_sprawozdanie\_Olaf\_Werner\_291139

May 4, 2020

## **1 Potwierdzam samodzielność powyższej pracy oraz niekorzystanie przeze mnie z niedozwolonych źródeł. Olaf Werner**

## **2 Wstęp**


Zbadamy działanie sieci Kohena na dwóch zbiorach danych: MNIST i UCI HAR. Będziemy testować w zależności od architektury sieci (sześciokątnej i kwadratowej) oraz funkcji sąsiedztwa: gaussowskiej i minus drugiej pochodnej funkcji gaussowskiej dalej zwaną "sombbrero". Sombbrero jest wygaszana 3 razy szybciej. Funkcją wygasającą będzie wykładnicza. Początkowe wagi neuronów będą losowane jednostajnie na przedziale  $[-1,1]$  i będą takie same dla wszystkich sieci w ramach danego zbioru danych. Weźmiemy architekturę 4 na 4 i będziemy trenować na losowym podzbiorze o wielkości  $1/10$  oryginalnego. Będziemy mieli 100 iteracji.

## **3 MNIST**

Normalizujemy dane poprzez podzielenie na 255, pomnożenie przez dwa i odjęcie 1.


### 3.1 Sześciokątna i gaussowska

### 3.2 Klasa i BMU dla każdej obserwacji testowej



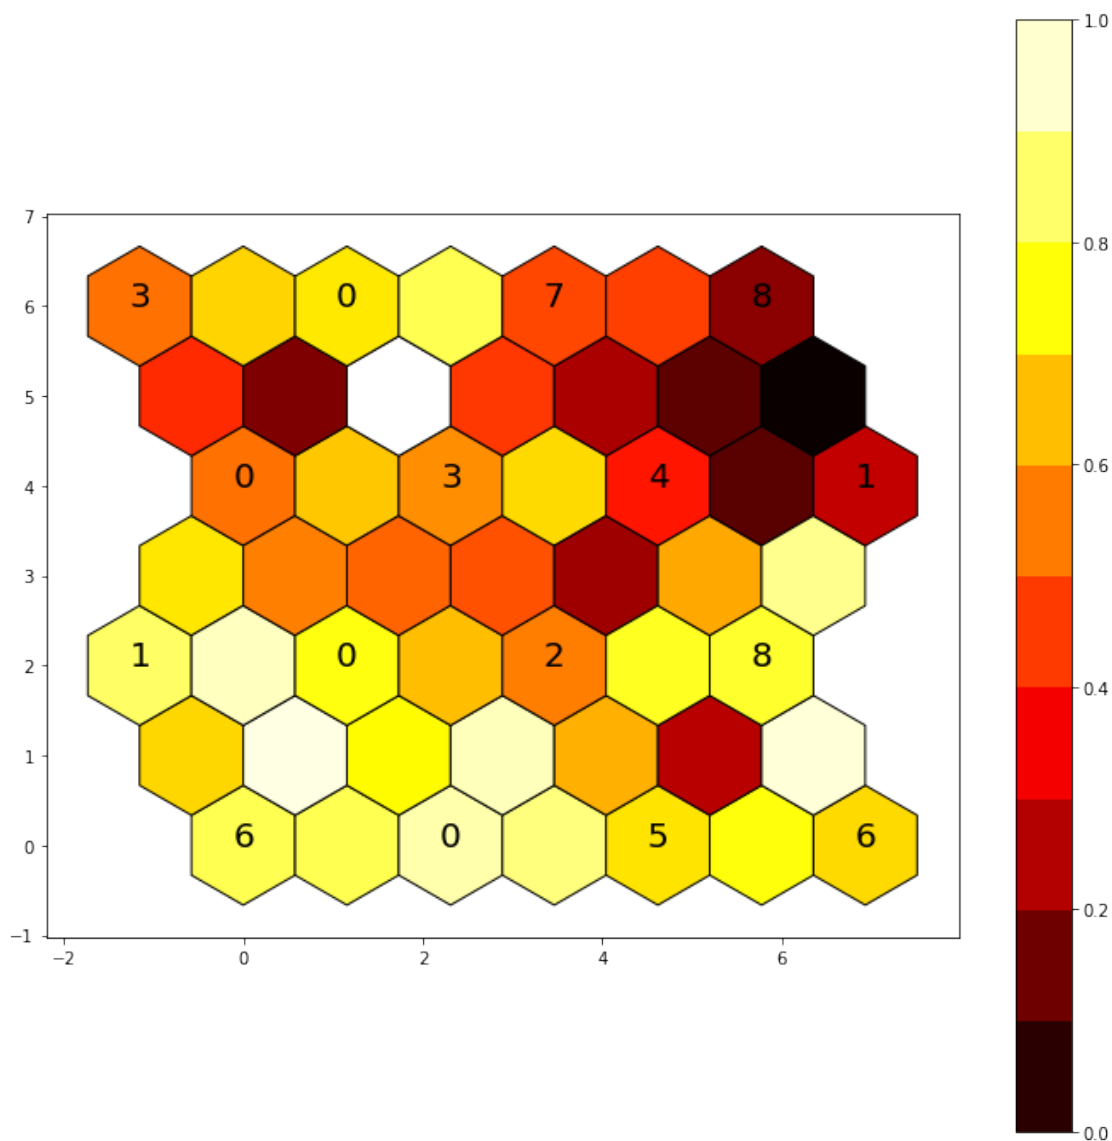
Widzimy że nasza sieć dobrze dopasowuje się do 0 i 6 reszta klastrów jest mocno wymieszana.

### 3.3 Czystość w zależności od neuronu



Tutaj i w dalszych wykresach czystość rozumiemy jako częstość występowania najczęściej występującej klasy. Ten wykres potwierdza nasze przypuszczenia o dobrym dopasowaniu 0 i 6, reszta jest dopasowana lepiej niż losowo, oprócz neuronu [0,3] który ma słabe rezultaty.


### 3.4 U Macierz



Liczby oznaczają tutaj najczęściej występującą klasę, zaś im ciemniejszy obszar tym bliżej siebie są dane klasy. Tu widzimy że 0 i 6 są bardzo dobrze rozdzielane od innych klas. To znaczy że ich neurony są znacząco inne od innych neuronów. Inne są bardziej do siebie podobne co tłumaczy ich niższą czystość.


### 3.5 Sześciokątna i sombrero

### 3.6 Klasa i BMU dla każdej obserwacji testowej




Mamy mniej klastrów niż klas to jest bardzo źle.

### 3.7 Czystość w zależności od neuronu



Oprócz 3 to inne liczby są prawie losowe.


### 3.8 U Macierz



Umacierz wyjaśnia co się stało. Neuron liczby 3 jest w miarę odizolowany od neuronów 4 i 1 które są bardzo blisko siebie co tłumaczy czemu 3 było w miarę czyste, zaś 4 i 1 nie. Pozostałe neurony są bardzo daleko od siebie nawzajem i naszych “działających” wynika to z tego że sombrero może dawać ujemne wartości przez co w trakcie uczenia neurony są “odpychane” od BMU.

### 3.9 Kwadratowa i gaussowska


### 3.10 Klasa i BMU dla każdej obserwacji testowej



Sieć dała podobne rezultaty co ta o architekturę sześciokątnej czyli 0 i 6 są dobrze separowane, reszta nie jest tak czysta.




### 3.11 Czystość w zależności od neuronu



Tutaj 9 też nigdzie nie jest najczęściej występującą wartością. 6 i 0 też są najlepsze.


### 3.12 U Macierz



Im ciemniej tym bliżej są siebie neurony. Możemy wyróżnić tu klaster 8 na górze, 0 w lewym centrum. Klasy 6 na dole są od siebie odseparowane 1. Podobnie jak w siatce sześciokątnej im bliżej siebie są różne liczby tym gorszej czystości są to klastry.


### 3.13 Kwadratowa i sombrero

### 3.14 Klasa i BMU dla każdej obserwacji testowej




Podobnie jak w przypadku sześciokątnej siatki. Mamy tylko 3 klastry.

### 3.15 Czystość w zależności od neuronu



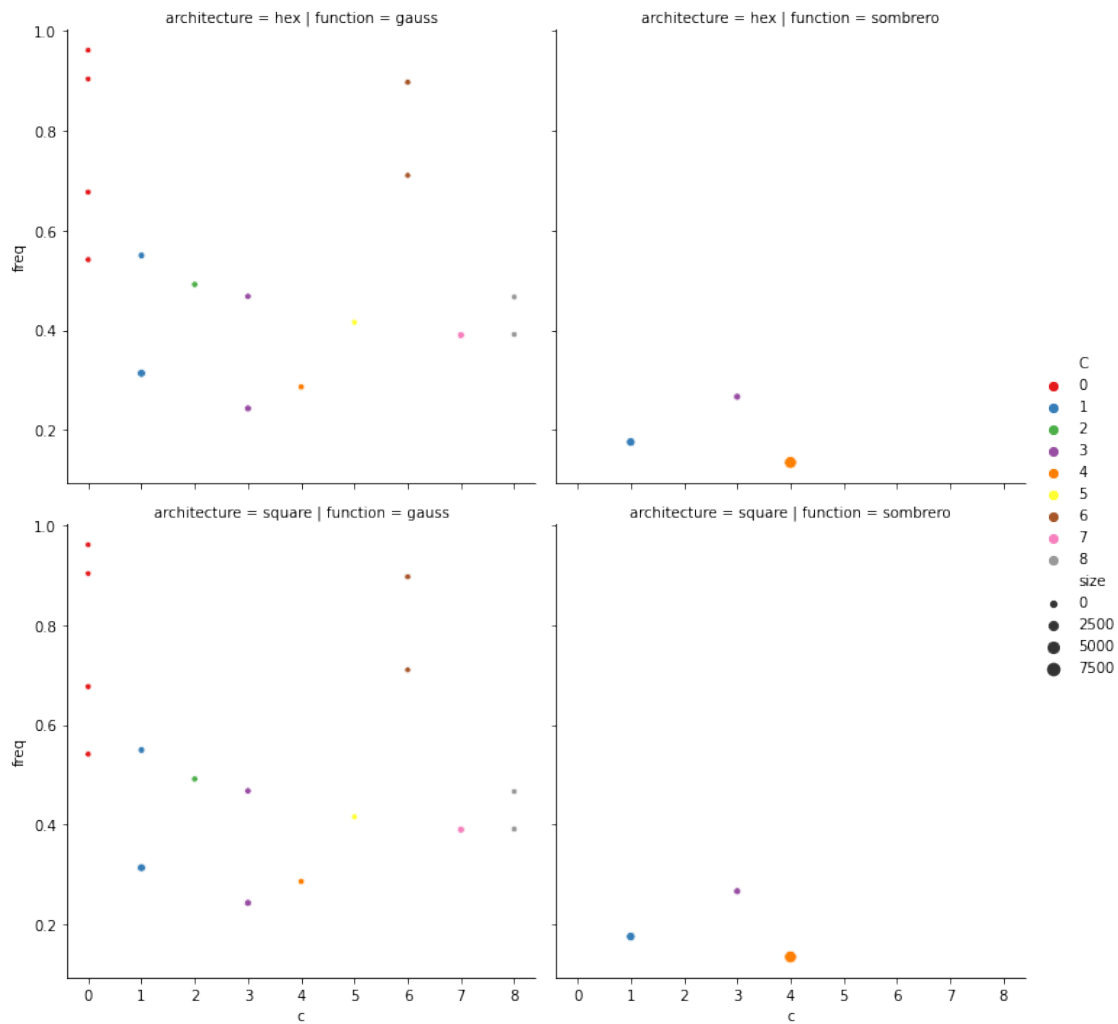
3 też zostało najlepiej dopasowane.

### 3.16 U Macierz



Tutaj neuron [2,1] został “odepchnięty” tak mocno że zmienił “kolorystykę” całej u macierzy. Klasty “działające” też są od siebie wyraźnie odseparowane, to znaczy że żaden ze sobą nie sąsiedował indeksowo jak to miało miejsce dla architektury sześciokątnej.

### 3.17 Podsumowanie




Obie architektury dają bardzo podobne rezultaty po dużej liczbie iteracji, zaś funkcja sombrero źle się zachowuje. Po za tym dla tego zbioru danych niektóre klasy są lepiej separowalne od innych. W przypadku funkcji gaussa nawet w najgorszym przypadku podział był lepszy niż losowy.

### 3.18 UCI HAR


### 3.19 Sześciokątna i gaussowska

### 3.20 Klasa i BMU dla każdej obserwacji testowej




Tutaj mamy bardzo dobrą separację dla leżenia. Jest prawie zupełnie czysta. Poza tym czynności są mieszane tylko z pewnymi innymi czynnościami: stanie z siedzeniem, oraz chodzenie w górę w dół i po prostu.

### 3.21 Czystość w zależności od neuronu



Leżenie jest prawie czyste, zaś reszta czynności ma czystość powyżej 0.5. Czystość schodzenia w dół w przypadkach [2,2] i [1,3] wynika z małego rozmiaru klastru.

### 3.22 U Macierz




Umacierz pokazuje podobieństwa pomiędzy siedzeniem, a leżeniem i separację pomiędzy staniem, a schodzeniem w dół. Widzimy też podobieństwo między schodzeniem w dół, a chodzeniem.




### 3.23 Sześciokątna i sombrero

### 3.24 Klasa i BMU dla każdej obserwacji testowej




Zła liczba klastrów. Ale są klastry aktywności ruchowych i pasywnych. Wykryto też dwa czyste klastry shodzenia w dół. Klaster [0,1] jest wymieszany

### 3.25 Czystość w zależności od neuronu



Oprócz dwóch małych klastrów schodzenia w dół to pozostałe mają małą czystość.


### 3.26 U Macierz



Klastry są od siebie odległe


### 3.27 Kwadratowa i gaussowska

### 3.28 Klasa i BMU dla każdej obserwacji testowej




Podobne wyniki do architektury sześciokątnej. Liczba klastrów jest jednak nieco inna.

### 3.29 Czystość w zależności od neuronu



Leżenie jest prawie czyste, zaś reszta czynności ma czystość powyżej 0.5. Czystość schodzenia w dół w przypadkach [2,1] i [3,1] wynika z małego rozmiaru klastru.

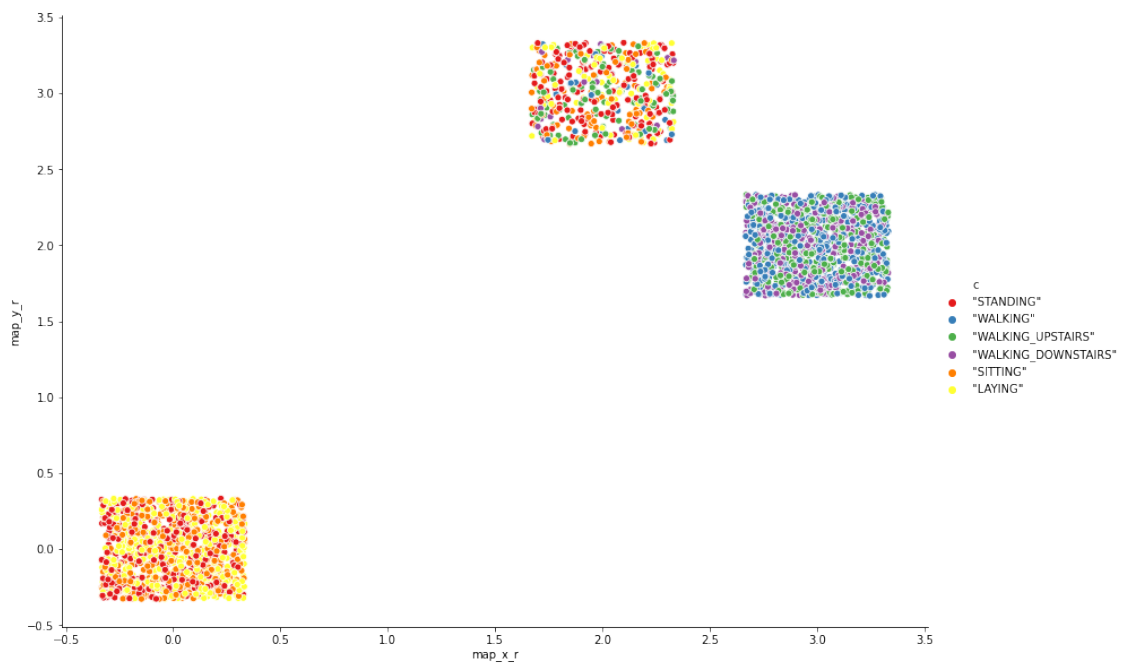
### 3.30 U Macierz



Siedzenie jest podobne do leżenia, zaś aktywności ruchowe są do siebie podobne.


### 3.31 Kwadratowa i sombrero

### 3.32 Klasa i BMU dla każdej obserwacji testowej



Mamy 3 klastry: jeden mieszany, jeden aktywności ruchowych i jeden aktywności pasywnych.


### 3.33 Czystość w zależności od neuronu



Wszystkie mają czystość lepszą od 0.34 ale gorszą od 0.4 co sugeruje że klasy w klastrach aktywności ruchowych i pasywnych są równomiernie rozłożone.




### 3.34 U Macierz



Mamy tu też do czynienia ze zjawiskiem “odepchnięcia” tutaj neuronu [2,2]. mamy też wyraźny podział między leżeniem, a resztą aktywności.

### 3.35 Podsumowanie



Tutaj w przypadku funkcji gaussa architektura kwadratowa okazała się lepsza od sześciokątnej. Zaś w przypadku funkcji sombrero jest na odwrót: architektura sześciokątna okazała się lepsza od kwadratowej. Po za tym to funkcja gaussa jest zdecydowanie lepsza od sombrero.

## 4 Ogólne wnioski

Funkcja sombrero poprzez możliwość otrzymywania ujemnych wartości może doprowadzić do dziwnych zachowań, więc odradzam jej używania. Architektura kwadratowa okazała się nie gorsza od sześciokątnej, ale ponieważ podania zostały wykonane tylko na dwóch zbiorach danych to jeszcze nie przesądza o jej wyższości nad sześciokątną. Po za tym okazało się że są klasy w zbiorach danych które są łatwiej separowalne od innych i to niezależnie od architektury.